Derin Öğrenme Tabanlı Tahmin Modelleri ve Temel Sinir Ağı Mimarileri

Günümüzde teknolojinini hızla gelişmesi ile beraber elde edilen veri miktarı da bir o kadar artmıştır. Bilimsel araştırmalar, sosyal medya platformları, sensör sistemleri ve dijital uygulamalar sürekli olarak büyük veri üretmektedir. Bu verilerin anlamlı bilgiye dönüştürülebilmesi ise güçlü veri analiz yöntemlerini gerekli kılmaktadır. Geleneksel yöntemler ve klasik makine öğrenmesi algoritmaları birçok problemde başarılı sonuçlar elde etse de veri miktarının artması ve veri yapılarının daha karmaşık hale gelmesi bu yöntemlerin bazı durumlarda yetersiz kalmasına neden olmuştur.

Bu noktada derin öğrenme yöntemleri önemli bir alternatif olarak ortaya çıkmıştır. Derin öğrenme, çok katmanlı yapay sinir ağlarını kullanarak veriler içerisindeki karmaşık ilişkileri öğrenebilen bir makine öğrenmesi yaklaşımıdır. Derin öğrenmenin en önemli özelliklerinden biri, veriden otomatik olarak anlamlı özellikler çıkarabilmesidir. Geleneksel makine öğrenmesi yöntemlerinde veri analizi öncesinde özellik çıkarımı genellikle araştırmacı tarafından yapılırken, derin öğrenme modelleri bu süreci büyük ölçüde otomatik hale getirmektedir.

Son yıllarda derin öğrenme yöntemleri birçok alanda dikkat çekici başarılar elde etmiştir. Görüntü tanıma, konuşma tanıma, doğal dil işleme ve tıbbi görüntü analizi gibi alanlarda derin öğrenme modelleri oldukça yüksek doğruluk oranları sağlayabilmektedir. Günümüzde yüz tanıma sistemleri, otonom araçlar, sesli asistanlar ve öneri sistemleri gibi birçok yapay zeka uygulamasının temelinde derin öğrenme yöntemleri bulunmaktadır.

Bu makalede derin öğrenme mimarileri ele alınmakta ve bu mimarilerin genel çalışma prensipleri açıklanmaktadır. Özellikle ileri beslemeli sinir ağları, evrişimsel sinir ağları, derin inanç ağları, autoencoder modelleri ve uzun kısa süreli bellek ağları gibi derin öğrenme yaklaşımlarının yapısı incelenmektedir. Bu mimariler günümüzde veri bilimi ve yapay zeka alanında en yaygın kullanılan modeller arasında yer almaktadır.

Yapay Sinir Ağlarının Keşfi ve Gelişimi

Yapay sinir ağlarının gelişimi aşağıda açıklanmıştır:

• 1943 yılında McCulloch ve Pitts, biyolojik bir nöronun işleyişini taklit etmeyi amaçlamayan ancak temel işlevlerini matematiksel olarak formüle eden ilk soyut nöron modelini oluşturmuştur.

• 1957 yılında Rosenblatt tarafından geliştirilen Perceptron, doğrusal bir ikili sınıflandırıcı olarak hizmet eden tek katmanlı bir sinir ağı modelidir.

• Ivakhnenko 1968 yılında katman ve birim sayısının önceden sabitlenmediği, öğrenilebilir yapıda olan ilk derin ileri beslemeli ağları (GMDH) tanıtmıştır.

• Minsky ve Papert 1969 yılında, Perceptron modelinin XOR gibi doğrusal olarak ayrılamayan problemleri çözemediğini kanıtlamış; bu durum sinir ağları çalışmalarında uzun bir duraklama dönemine yol açmıştır.

• 1980'li yıllarda geri yayılım algoritmasının sinir ağlarında denetimli öğrenme için etkili bir şekilde kullanılabileceğinin gösterilmesiyle araştırmalar yeniden hız kazanmıştır.

• 2006 yılında Hinton ve ekibi, Derin İnanç Ağlarının katman katman ön eğitim stratejisiyle verimli şekilde eğitilebileceğini göstermiş ve derin öğrenme kavramının yaygınlaşmasına önemli katkı sağlamıştır.

• 2012 yılında Alex Krizhevsky tarafından geliştirilen AlexNet modelinin ImageNet yarışmasında elde ettiği başarı, derin öğrenmenin özellikle görüntü tanıma alanında ne kadar güçlü olduğunu göstermiştir.

Bu gelişmelerin ardından yapay sinir ağlarına olan ilgi yeniden artmış ve derin öğrenme günümüzde yapay zeka araştırmalarının en önemli alanlarından biri haline gelmiştir.

Yapay Sinir Ağlarının Temel Yapısı

Yapay sinir ağları, insan beynindeki nöronların çalışma prensiplerinden esinlenerek geliştirilen matematiksel modellerdir. Ancak bu modeller insan vücudundaki sistemi taklit etmek amacıyla değil, verileri analiz etmek ve buna bağlı olarak tutarlı tahminler üretmek amacıyla tasarlanmıştır. Bir yapay sinir ağı çok sayıda yapay nörondan oluşur ve bu nöronlar katmanlar halinde birbirine bağlanır.Bir yapay nöronun yaptığı işlem kendisine gelen giriş değerlerini ağırlıklarla çarpmsk ve elde edilen değerleri toplamaktır. Daha sonra bu toplam değer bir aktivasyon fonksiyonundan geçirilir ve nöronun çıktısı elde edilir. Aktivasyon fonksiyonları sinir ağlarının doğrusal olmayan ilişkileri öğrenebilmesini sağlar. Bu özellik sayesinde sinir ağları karmaşık veri yapılarını analiz edebilir.Analizler sonucunda da tahmin değerleri elde edilir. Bu klasik makine öğrenmesi yöntemlerine göre daha hızlı ve tutarlı sonuçlar üretmektedir.

Sinir ağlarında kullanılan aktivasyon fonksiyonları arasında sigmoid, tanh ve ReLU gibi fonksiyonlar bulunmaktadır. Derin öğrenme modellerinde en yaygın olarak tercih edilen aktivasyon fonksiyonu ReLU fonksiyonudur. ReLU'nun tercih edilme sebebi hesaplama açısından daha verimli olmasıdır.Çok katmanlı yapı sayesinde sinir ağları veriyi farklı soyutlama seviyelerinde işleyebilir.

Genel olarak bir sinir ağı üç temel katmandan oluşur. Giriş katmanı veriyi modele iletir. Gizli katmanlar veriyi işleyerek modelin önemli özellikleri öğrenmesini sağlar. Çıkış katmanı ise modelin gerçek tahminlerini üretir. Bu yapı sayesinde sinir ağları karmaşık veri ilişkilerini öğrenebilir ve çeşitli tahmin problemlerinde kullanılabilir.

İleri Beslemeli Sinir Ağları (Feedforward Neural Networks – FFNN)

İleri beslemeli sinir ağları, yapay sinir ağlarının en temel mimarilerinden biridir. Bu tür ağlarda bilgi akışı giriş katmanından başlayarak gizli katmanlar üzerinden çıkış katmanına doğru ilerler. Ağ içerisinde geri bağlantı bulunmadığı için veri akışı tek yönlüdür.

Bu mimari genellikle çok katmanlı algılayıcılar olarak da adlandırılır. Bu yapı sayesinde model daha karmaşık veri ilişkilerini öğrenebilir. Tek katmanlı perceptron modelleri yalnızca doğrusal problemleri çözebilirken, çok katmanlı yapılar doğrusal olmayan problemleri de çözebilmektedir.Bu da büyük avantaj sağlamaktadır.

İleri beslemeli sinir ağlarının eğitimi çoğunlukla geri yayılım algoritması ile gerçekleştirilir. Bu algoritma modelin yaptığı tahmin ile gerçek değer arasındaki farkı hesaplar ve hata değerine göre ağın ağırlıklarını günceller. Eğitim süreci boyunca modelin hata değeri azaltılmaya çalışılır.Bu tür ağlar sınıflandırma ve regresyon problemlerinde oldukça yaygın olarak kullanılmaktadır. Basit bir yapıya sahip olmasına rağmen ileri beslemeli sinir ağları birçok veri analizi probleminde başarılı sonuçlar elde edilebilmektedir.

Evrişimsel Sinir Ağları (Convolutional Neural Networks – CNN)

Evrişimsel sinir ağları özellikle görüntü verilerinin analizinde kullanılan derin öğrenme modelleridir. Geleneksel sinir ağlarında her nöron bir sonraki katmandaki tüm nöronlara bağlıdır. Bu durum parametre sayısının oldukça artmasına neden olabilir. CNN mimarisinde ise yerel bağlantı prensibi kullanılarak bu sorun büyük ölçüde azaltılmıştır.

CNN modelleri genellikle evrişim katmanları, havuzlama katmanları ve tam bağlantılı katmanlardan oluşur. Evrişim katmanları görüntü üzerinde filtreler kullanarak özellik çıkarımı yapar. Bu filtreler görüntüdeki kenarlar, köşeler ve farklı şekiller gibi temel özellikleri öğrenebilir.Havuzlama katmanları ise verinin boyutunu küçültür ve modelin hesaplama maliyetini azaltır. Aynı zamanda modelin genelleme yeteneğini artırarak aşırı öğrenme problemini azaltmaya yardımcı olur. Tam bağlantılı katmanlar ise öğrenilen özellikleri kullanarak sınıflandırma işlemini gerçekleştirir.

CNN mimarileri günümüzde yüz tanıma, nesne tespiti ve tıbbi görüntü analizi gibi birçok alanda kullanılmaktadır. Günümüzde evrişimsel sinir ağlarının gelişmesiyle farklı mimariler ortaya çıkmıştır ve bunlar görüntü işleme alanında önemli faydalar sağlamıştır. Aşağıda bu mimarilerden en yaygın kullanılanlarına değinilmiştir:

- **LeNet:** Evrişimsel sinir ağlarının ilk örneklerinden biri olarak kabul edilmektedir ve 1990'lı yıllarda Yann LeCun tarafından geliştirilmiştir. Bu model özellikle el yazısı rakam tanıma problemlerinde kullanılmıştır. LeNet mimarisi temel olarak evrişim katmanları, havuzlama katmanları ve tam bağlantılı katmanlardan oluşmaktadır. Bu model, görüntülerden özellik çıkarımı yaparak basit sınıflandırma problemlerini çözebilen ilk başarılı CNN mimarilerinden biri olması açısından önemli bir yere sahiptir. Günümüzde daha gelişmiş CNN modelleri kullanılsa da LeNet, evrişimsel sinir ağlarının gelişiminde önemli bir başlangıç noktası olarak kabul edilmektedir.
- **AlexNet:** 2012 yılında Alex Krizhevsky ve çalışma arkadaşları tarafından geliştirilmiş ve ImageNet yarışmasında elde ettiği yüksek başarı ile derin öğrenmenin popüler hale gelmesine önemli katkı sağlamıştır. Bu model, geleneksel yöntemlere kıyasla çok daha yüksek doğruluk oranları elde ederek görüntü sınıflandırma alanında önemli bir dönüm noktası olmuştur. AlexNet mimarisinde birden fazla evrişim katmanı ve tam

bağlantılı katman kullanılmıştır. Ayrıca modelde ReLU aktivasyon fonksiyonu, dropout yöntemi ve GPU tabanlı eğitim gibi yenilikçi yaklaşımlar kullanılmıştır. Bu özellikler AlexNet modelinin daha hızlı eğitilmesini ve daha yüksek performans elde edilmesini sağlamıştır.

- **VGGNet:** Oxford Üniversitesi Visual Geometry Group tarafından geliştirilmiştir ve daha derin sinir ağı yapıları kullanarak model performansını artırmayı amaçlamaktadır. Bu mimaride genellikle küçük boyutlu (3×3) filtreler kullanılarak çok sayıda evrişim katmanı oluşturulmuştur. Bu yaklaşım sayesinde model görüntülerdeki karmaşık özellikleri daha iyi öğrenebilmektedir. VGGNet mimarisi, sade ve düzenli yapısı nedeniyle araştırmacılar tarafından yaygın olarak kullanılmaktadır. Ancak modelin çok sayıda parametre içermesi nedeniyle hesaplama maliyeti oldukça yüksek olabilmektedir.
- **GoogLeNet:** Google araştırmacıları tarafından geliştirilmiş olup inception modülleri ile dikkat çekmektedir. Bu mimaride farklı boyutlardaki filtreler aynı anda kullanılarak modelin farklı ölçeklerde özellik öğrenmesi sağlanmaktadır. Inception modülü sayesinde model hem daha derin hem de daha verimli bir yapıya sahip olmuştur. GoogLeNet mimarisi aynı zamanda parametre sayısını azaltarak daha düşük hesaplama maliyeti ile yüksek performans elde edilmesine olanak tanımaktadır. Bu özellikleri sayesinde GoogLeNet, görüntü sınıflandırma problemlerinde oldukça başarılı sonuçlar elde etmiştir.
- **ResNet:** Çok derin sinir ağlarının eğitiminde ortaya çıkan performans düşüşü problemini çözmek amacıyla geliştirilmiştir. Bu mimaride residual bağlantılar kullanılarak bilginin katmanlar arasında doğrudan aktarılması sağlanmaktadır. Bu yaklaşım sayesinde yüzlerce katmana sahip çok derin sinir ağlarının eğitilmesi mümkün hale gelmiştir. ResNet mimarisi özellikle görüntü tanıma ve nesne tespiti gibi alanlarda oldukça başarılı sonuçlar elde etmiş ve derin öğrenme çalışmalarında yaygın olarak kullanılan modellerden biri haline gelmiştir.

Autoencoder (Oto Kodlayıcı) Modelleri ve Temsil Öğrenme Yaklaşımı

Autoencoder modelleri, gözetimsiz öğrenme yöntemleri arasında yer alan ve verinin daha düşük boyutlu bir temsilini öğrenmeyi amaçlayan sinir ağı modelleridir. Bu modeller temel olarak iki ana bölümden oluşmaktadır: kodlayıcı ve çözücü . Kodlayıcı bölüm giriş verisini daha düşük boyutlu bir temsil haline dönüştürürken, çözücü bölüm ise bu temsil üzerinden giriş verisini yeniden üretmeye çalışır. Modelin yapısında giriş ve çıkış katmanlarının boyutu genellikle aynıdır. Modelin ortasında yer alan dar katman ise verinin sıkıştırılmış temsilini oluşturur. Bu yapı sayesinde model verideki önemli özellikleri öğrenerek gereksiz bilgileri ortadan kaldırabilir. Bu nedenle autoencoder modelleri özellikle boyut indirgeme ve özellik çıkarımı gibi problemlerde etkili bir şekilde kullanılmaktadır.

Autoencoder modellerinin farklı türleri de bulunmaktadır. Örneğin gürültü giderici autoencoder modelleri (Denoising Autoencoder) veride bulunan gürültüyü azaltmayı amaçlarken, seyrek autoencoder modelleri (Sparse Autoencoder) daha anlamlı veri temsilleri öğrenmeye odaklanmaktadır. Ayrıca varyasyonel autoencoder (Variational Autoencoder) gibi

gelişmiş modeller veri üretimi ve generatif modelleme alanlarında kullanılmaktadır.Bu özellikleri sayesinde autoencoder modelleri görüntü işleme, veri sıkıştırma, anomali tespiti ve özellik öğrenme gibi birçok farklı uygulama alanında kullanılabilmektedir.

Zaman Bağımlı Veriler İçin LSTM Ağları

Uzun kısa süreli bellek ağları (LSTM), zaman bağımlı verilerin analizinde kullanılan özel bir tekrarlayan sinir ağı türüdür. Klasik sinir ağlarında uzun veri dizileri üzerinde eğitim yapılırken gradyan kaybolması veya gradyan patlaması gibi problemler ortaya çıkabilmektedir. LSTM mimarisi bu problemi azaltmak amacıyla geliştirilmiştir.

LSTM ağları, bilgiyi daha uzun süre saklayabilen özel bir hücre yapısına sahiptir. Bu mimaride giriş kapısı, unutma kapısı ve çıkış kapısı olmak üzere üç temel kontrol mekanizması bulunmaktadır. Giriş kapısı yeni bilgilerin hücreye ne kadar aktarılacağını belirlerken, unutma kapısı geçmiş bilgilerin ne kadarının saklanacağına karar verir. Çıkış kapısı ise hücrede tutulan bilginin ağın sonraki katmanlarına ne şekilde aktarılacağını belirler. Bu kapı mekanizmaları sayesinde LSTM modelleri uzun zaman bağımlılıklarını öğrenebilme yeteneğine sahiptir. Bu nedenle özellikle zaman serisi verilerinin analizinde oldukça başarılı sonuçlar elde edilmektedir. LSTM ağları günümüzde konuşma tanıma, makine çevirisi, metin üretimi ve finansal zaman serisi tahmini gibi birçok alanda yaygın olarak kullanılmaktadır.

Sonuç

Derin öğrenme yöntemleri günümüzde yapay zeka araştırmalarının en önemli alanlarından biri haline gelmiştir. Büyük veri setlerinin artmasıyla birlikte geleneksel makine öğrenmesi yöntemlerinin bazı problemlerde yetersiz kalması, araştırmacıları daha güçlü öğrenme yöntemleri geliştirmeye yöneltmiştir. Bu bağlamda çok katmanlı yapay sinir ağlarına dayanan derin öğrenme modelleri, karmaşık veri yapılarının analiz edilmesinde önemli avantajlar sağlamaktadır.